

EuroSAT RGB 图像分类实验报告

1. 实验目标

本次作业要求使用多层感知机（MLP）完成 EuroSAT RGB 数据集的图像分类。EuroSAT RGB 数据集共有 10 个类别，包括 AnnualCrop、Forest、Highway、Industrial、River、SeaLake 等。实验中严格不使用 PyTorch、TensorFlow、JAX 或自动微分框架；模型的前向传播、反向传播、交叉熵损失、SGD 更新、学习率衰减和 L2 weight decay 都用 NumPy 手写实现。

由于 MLP 需要把图像展平成一维向量，直接使用 $64 \times 64 \times 3$ 的输入会让第一层参数量和计算量都变得很大。为了让纯 NumPy 实验和网格搜索能够在合理时间内完成，本实验将输入图像统一缩放到 16×16 ，再展平为 768 维向量。这个设置也可以看作一种下采样预处理：它会损失部分细节，但能降低优化难度，并减少 MLP 在高维输入上的过拟合风险。

2. 数据处理与划分

所有图像首先从 RGB 格式读入，并缩放到 16×16 。像素值被归一化到 $[0, 1]$ ，随后使用训练集的均值和标准差进行标准化。数据集按照类别分层划分为训练集、验证集和测试集，比例为：

```
train : validation : test = 70% : 15% : 15%
```

验证集用于选择超参数和保存最佳模型权重，测试集只在确定最佳模型后使用一次，用来报告最终性能。

3. 模型结构与训练方法

模型为一层隐藏层的 MLP：

```
Input -> Linear -> ReLU -> Linear -> Softmax
```

其中隐藏层大小作为超参数搜索。损失函数为交叉熵损失，并在权重矩阵上加入 L2 weight decay。优化器为 mini-batch SGD，batch size 固定为 256。学习率采用指数衰减：

```
lr_t = lr_0 * decay^(t - 1)
```

每个 epoch 结束后，程序都会在验证集上计算 loss 和 accuracy。如果当前验证集准确率超过历史最佳值，就保存当前模型权重。训练结束后，测试集评估使用的是验证集表现最好的权重，而不是最后一个 epoch 的权重。

4. 超参数搜索

本实验在 16×16 输入下进行完整网格搜索。为了保持作业实现简洁，激活函数固定为 ReLU；相比 Sigmoid/Tanh，ReLU 在该任务上训练更直接，也更不容易出现梯度过小的问题。主要搜索以下超参数：

```
hidden_dim: 128, 256, 512
learning_rate: 0.005, 0.01, 0.02, 0.04, 0.08, 0.12, 0.16
lr_decay: 0.90, 0.94, 0.95, 0.97
weight_decay: 0, 1e-4, 5e-4
```

由于低学习率和高学习率区域的搜索是分批完成的，最终整理后的结果统一放在：

```
grid_search_results_numpy16/
```

其中 grid_results.csv 记录了所有有效超参数组合的表现，包括 best epoch、best validation accuracy、final train accuracy 和 final validation accuracy。最终按验证集最高准确率选择模型。

4.1 最优超参数

hidden dim	learning rate	lr decay	weight decay	best epoch	best val acc	test acc
512	0.16	0.90	5e-4	30	0.6859	0.6881

最佳模型配置为：

```
image_size = 16
hidden_dim = 512
activation = ReLU
learning_rate = 0.16
lr_decay = 0.90
weight_decay = 5e-4
batch_size = 256
best_epoch = 30
```


测试集结果为：

```
test loss = 1.1440
test accuracy = 0.6881
```

从搜索结果看，较大的隐藏层和较高的初始学习率整体表现更好。 16×16 输入维度较低，因此可以承受 0.12 或 0.16 这样的学习率；低学习率组合虽然更稳定，但在 30 个 epoch 内收敛较慢。

5. 实验结果


5.1 Loss 与 Accuracy 曲线



Learning curves

训练准确率整体持续上升，验证准确率在后期逐渐趋于平稳。最佳模型出现在第 30 个 epoch。训练集准确率略高于验证集，说明模型存在一定过拟合，但验证集准确率没有明显下降，因此该模型仍然是网格搜索中最合适的选择。

5.2 混淆矩阵




最终模型在测试集上的总准确率为 68.81%。各类别的测试表现如下：

类别	测试样本数	正确数	类别准确率
AnnualCrop	450	276	0.613
Forest	450	396	0.880
HerbaceousVegetation	450	242	0.538
Highway	375	141	0.376
Industrial	375	333	0.888
Pasture	300	232	0.773
PermanentCrop	375	198	0.528
Residential	450	370	0.822
River	375	251	0.669
SeaLake	450	348	0.773

Industrial、Forest 和 Residential 的识别效果较好，说明 MLP 能够利用这些类别比较稳定的颜色和纹理统计。Highway、PermanentCrop 和 HerbaceousVegetation 的准确率较低，说明这些类别更依赖局部形状或细粒度纹理，而展平后的 MLP 对这类结构信息利用有限。

5.3 错例分析



Error examples

主要错误集中在以下几类：

- HerbaceousVegetation 容易被预测成 Residential。低分辨率下，大片植被和带有绿色背景的住宅区在颜色和纹理上比较接近。
- Highway 经常被预测成 River 或 Residential。道路和河流都可能是细长结构；道路周围如果有建筑或灰色区域，也容易和住宅区混淆。
- PermanentCrop 容易被分到 AnnualCrop 或 HerbaceousVegetation。这几类都和农田或植被纹理有关，在 16×16 输入下细节差异会进一步减弱。
- SeaLake 有一部分被预测成 Forest，可能是湖岸、阴影或大面积深色区域造成的混淆。


这些错误说明，MLP 对整体颜色和粗粒度纹理比较敏感，但缺少卷积网络那种局部结构建模能力。对于 Highway/River 这类依赖形状的分类，单纯展平输入的限制比较明显。

5.4 第一层权重可视化

为了观察模型是否学到了一些空间纹理或颜色模式，我将第一层权重矩阵恢复成图像进行可视化。最终模型中第一层权重 $W1$ 的形状为：

$$(16 * 16 * 3, 512) = (768, 512)$$


每一列对应一个隐藏单元的输入权重。我将每一列 reshape 成 $16 \times 16 \times 3$ ，再按 1% 到 99% 分位数归一化成 RGB 图像。下面展示的是 L2 范数最大的 36 个隐藏单元。



First-layer weight grid

这些权重图没有呈现非常清晰的物体轮廓，这符合 MLP 的特点：模型没有卷积层，也没有权重共享机制。不过，部分隐藏单元仍然出现了块状区域、横向或纵向的亮暗变化，以及明显的颜色偏置，说明模型确实是在利用粗粒度颜色分布和空间纹理。

隐藏单元本身不直接对应某个类别。为了更系统地观察每个类别相关的模式，我进一步查看第二层权重 W_2 。对于某个类别，如果某个隐藏单元连接到该类别 logit 的权重较大，就说明该隐藏单元的激活会更强地推动模型预测该类别。因此，我对 10 个类别都选出第二层正向连接最强的 6 个隐藏单元，并把这些隐藏单元在第一层中的输入权重恢复成图像。



All class related first-layer weights

从这张图可以看到，不同类别确实对应到了一些不同的颜色和粗空间模式：


- 植被和农田相关类别中，相关权重经常出现绿色通道较强的块状模式。典型类别包括 Forest、Pasture、PermanentCrop 和 AnnualCrop。
- 人工地表类别更常出现蓝灰、浅色或红色偏置。Industrial 和 Residential 的相关权重与建筑、道路、屋顶等颜色统计比较一致。
- Highway 和 River 的相关隐藏单元都有带状或局部方向性模式，但这些模式并不稳定。两类都可能在低分辨率图像中表现为穿过画面的细长结构。
- SeaLake 有一定蓝/绿倾向，但不是纯蓝色模板。湖岸、阴影、植被或深色背景都会让模型学到混合的颜色统计。

为了让观察不完全停留在主观读图上，我还计算了每个类别近似模板的 RGB 通道均值和空间强度峰值。这个统计结果保存在 `grid_search_results_numpy16/weight_pattern_stats.csv`。其中 `dominant channel` 表示近似类别模板中均值最大的颜色通道。

类别	主导通道	简要观察
AnnualCrop	G	绿色略强，符合农田/作物的大面积植被特征。
Forest	G	绿色通道较强，区域连续性较明显，是最符合直觉的一类。
HerbaceousVegetation	R	模板偏红，说明模型可能更多利用亮度/土壤或背景差异，而不是单纯绿色。
Highway	R	有局部带状响应，但颜色模式不稳定，容易和 River/Residential 混淆。
Industrial	B	蓝灰色倾向明显，可能对应屋顶、道路、硬化地表等人工区域。
Pasture	G	绿色通道最强，和草地/牧场的大面积植被纹理一致。
PermanentCrop	G	与 AnnualCrop、HerbaceousVegetation 类似，绿色块状纹理较多，因此也容易混淆。
Residential	R	偏红/浅色，可能对应屋顶和建筑纹理。
River	G	有绿色和少量蓝色成分，同时出现带状区域，但并不是非常清楚的“河流形状”。
SeaLake	G	带有蓝绿混合倾向，可能受到湖岸和周围植被影响。

这里的颜色通道统计不能被理解为“模型只看某一种颜色”。它只是说明在近似线性模板中，哪些颜色方向更容易提高对应类别的 logit。由于 MLP 中间有 ReLU 非线性，真实决策还会受到隐藏单元激活状态影响。

题目中特别提到的 Forest 和 River 可以更细看一下。下图单独展示了这两个类别输出权重最大的 8 个隐藏单元。



Forest and River related first-layer weights

Forest 相关隐藏单元整体更容易出现绿色通道较强、区域较连续的模式。这和森林图像通常具有大面积绿色纹理相符，也对应了 Forest 在测试集上较高的类别准确率。

River 相关隐藏单元的模式没有森林那么单一。部分单元呈现出狭长或局部带状的亮暗变化，但也混有绿色和蓝色倾向。这与混淆矩阵中的现象一致：River 与 Highway 之间仍然容易混淆，因为二者都可能在低分辨率遥感图像中表现为贯穿画面的细长结构。

另外，我还计算了一个近似类别模板：对每个类别计算 $W1 @ W2[:, \text{class}]$ ，再 reshape 成图像。这个模板忽略了 ReLU 的门控作用，因此不能严格解释为真实输入梯度，但可以粗略反映哪些颜色和空间区域会提高某个类别的 logit。



Linearized class templates

从类别模板看，MLP 的第一层确实提取到了一些颜色和粗粒度空间纹理：植被类更偏绿色，人工地表类更偏蓝灰或红色，线状地物类有一定带状响应。但这些模式比较分散，缺少稳定的局部边缘、曲线或形状检测器。也就是说，MLP 学到的是“颜色统计 + 粗空间位置”的组合，而不是像 CNN 那样清晰的局部纹理滤波器。这一点和模型在 Highway、River、PermanentCrop 等类别上的错误情况是吻合的。

6. 结论

本实验在严格 NumPy 条件下实现了 EuroSAT RGB 的 MLP 分类器，并完成了交叉熵损失、SGD、学习率衰减、L2 weight decay、验证集最佳权重保存、网格搜索和测试集评估。最终模型使用 16×16 输入、一层 512 维 ReLU 隐藏层，在测试集上达到 68.81% 的准确率。

实验结果表明，MLP 可以利用遥感图像中的整体颜色和粗粒度纹理信息，对 Forest、Industrial、Residential 等类别取得较好效果。但由于图像被展平，模型缺少局部空间归纳偏置，因此在 Highway/River、作物/植被等容易混淆的类别上表现较弱。第一层权重可视化也支持这一点：模型学到了一些颜色和区域纹理模式，但没有形成非常清晰稳定的局部形状检测器。